

2048 深度强化学习项目

实验路线图

从可复现环境到 DQN、消融实验与 PPO 对照

实验准备版 v1.0

核心原则：先建立可信基线，再逐项改变变量；所有结论必须由重复实验与固定评估协议支持。

依据前期多轮方案推演整理

目录与使用方式

这是一份执行型文档。建议先阅读“总体结论”，随后按阶段推进；每完成一个阶段，只允许进入下一阶段中标记为 P0 的项目。

1. 总体结论：理论阶段是否结束
2. 已冻结的任务定义与尚待实验校准的变量
3. 实验基础设施与环境验收
4. 基线算法：Masked Double DQN
5. 阶段化实验矩阵
6. 评估协议与统计报告
7. VAE 与 PPO 的后续研究分支
8. 日志、复现、失败诊断和最终交付物

1. 总体结论：理论阶段基本结束，但不是“一切参数都已确定”

目前已经完成了从任务目标、MDP 规则、终止与截断、动作掩码、状态表示、统计评估，到价值方法和策略方法选择的主体理论设计。因此下一步应当进入实验阶段，而不是继续无限讨论抽象方案。

阶段判断：可以正式开始编码和实验。接下来仍会出现理论问题，但它们应由小规模试验、日志与消融结果触发，而不是在没有数据时继续预先争论。

仍需由实验而非纯理论决定的项目包括：

- **步数上限：**不能随意固定为 1000；应根据自然 episode length 分布和截断率校准。
- **折扣因子与 n-step：**需要比较长期性、价值尺度与训练稳定性的平衡。
- **表示和网络：**指数/one-hot 与 MLP/CNN 的效果不能只靠直觉判断。
- **奖励变换：**线性缩放主要影响数值尺度；对数压缩会改变任务偏好，必须作为独立实验。
- **VAE 与 PPO：**属于第二阶段研究分支，不应阻塞首个可靠 DQN 基线。

2. 冻结的任务定义

项目项	冻结定义	实施备注
任务目标	存活尽可能久、累积更高分并制造更大方块	达到 2048 不结束；P(达到 2048) 作为主要评估指标
观察	当前 4×4 棋盘	基础编码为指数：空格 0，2/4/8…分别为 1/2/3…
动作	上、下、左、右四个离散动作	基础方案使用精确合法动作掩码
有效动作	滑动后棋盘发生变化	仅有效动作后生成新方块
生成规则	空格位置均匀抽样；2 的概率 0.9，4 的概率 0.1	训练、验证、测试使用同一规则
自然终止	不存在任何能改变棋盘的动作	棋盘塞满但有相邻相等方块时并未终止
截断	达到人工步数上限	terminated=False, truncated=True; TD target 继续 bootstrap
成功事件	首次出现 2048 或更大方块	记录为指标，不改变环境终止状态

3. 环境实现与验收（P0，必须先完成）

在训练任何神经网络之前，环境必须通过确定性单元测试。否则后续所有曲线都可能是在拟合错误规则。

3.1 环境 API 建议

```
reset(seed) -> observation, info
```

```
step(action) ->
    next_observation,
    reward,
    terminated,
    truncated,
    info
```

info 至少包含：

```
valid_action_mask
merge_score
game_score
max_tile
episode_length
reached_2048
```

3.2 必须覆盖的单元测试

类别	测试内容	通过标准
滑动规则	无合并、单次合并、连续相同方块、间隔空格、边界移动	与手算棋盘完全一致
一次合并限制	如 [2,2,2,2] 的移动结果	每个新方块每步最多参与一次合并
无效动作	棋盘不变	不生成新方块, reward=0, episode length 是否计数需固定
生成概率	大量采样位置和 2/4 比例	位置近似均匀, 数值比例接近 0.9/0.1
终止检测	满盘可合并与满盘不可合并	仅后者 terminated=True
种子复现	相同 seed 和相同动作序列	生成完全一致的轨迹
对称一致性	对棋盘和动作做 D4 变换	变换前后一步结果满足等变关系

3.3 步数上限的校准

先不设置过低上限，运行随机策略、固定方向策略和简单启发式策略，记录自然结束长度分布。随后选择一个让强基线被截断比例很低的上限。

- 收集至少数千局自然 episode length。
- 报告中位数、P90、P95、P99 以及最大值。
- 候选上限可从 P99 以上开始，避免把“达到 2048”偷换成“在某个较短时限内达到 2048”。

12. 所有截断状态必须保存 `next_state`；训练停止采样，但 TD target 继续估计未来价值。

4. 参考策略与非神经网络基线（P0）

神经网络之前先建立最低限度的比较对象和调试工具。

基线	作用	至少报告
均匀随机合法动作	检验环境、评估脚本与最低性能	分数分布、最大方块分布、P(2048)、episode length
固定优先级策略	如左→下→右→上，仅作可复现弱基线	与随机策略比较
简单启发式策略	例如空格数、单调性、平滑度与角落大块加权	作为较强非学习基线
Oracle 一步贪心	每步选择即时合并分最高的合法动作	用于诊断智能体是否只是追逐即时奖励

验收门槛：只有当环境结果可复现、随机基线合理、启发式基线明显优于随机策略时，才进入 DQN。

5. 首个可训练基线：Masked Double DQN（P0）

建议不要以最原始、最脆弱的 DQN 作为唯一基线。首个稳定实现可采用 Double DQN + target network + replay buffer + Huber loss + gradient clipping，同时保留一个开关以退化成普通 DQN，方便后续做严格对照。

5.1 基线输入与网络

- **输入：**16 维指数向量，空格为 0；可按固定常数做线性缩放，但必须记录。
- **网络：**小型 MLP，输出四个 Q 值；不要一开始加入 CNN、VAE、dueling 等多个结构。
- **输出：** $Q(s, \text{up/down/left/right})$ ，不是动作概率。
- **行为策略：**训练使用逐步衰减 ϵ -greedy；随机动作和贪心动作都只在合法集合中选择。
- **验证/测试：** $\epsilon=0$ ，采用确定性贪心动作，并固定并列动作的 tie-breaking 规则。

5.2 一条经验的完整训练流程

1. 读取状态 s ，并计算 `valid_mask(s)`
2. 以概率 `epsilon`：
 - 从合法动作中均匀随机选 a
 - 否则：
 - $a = \operatorname{argmax}_a Q_{\text{online}}(s, a)$ ，无效动作临时置为 `-inf`
3. 执行环境 `step(a)`，得到：
 - $s_{\text{next}}, r, \text{terminated}, \text{truncated}, \text{info}$
4. 写入 replay：
 - $(s, a, r, s_{\text{next}}, \text{terminated}, \text{truncated}, \text{info})$

```
valid_mask(s), valid_mask(s_next))
```

5. 从 replay 采样 batch

6. Double DQN 选择下一动作:

```
a* = argmax_{合法 a'} Q_online(s_next, a')
```

7. Target 网络评价:

```
y = r + gamma * (1 - terminated) *
```

```
Q_target(s_next, a*)
```

注意: truncated 不切断 bootstrap

8. 拟合 $Q_{\text{online}}(s, a) \rightarrow y$, 使用 Huber loss

9. 梯度裁剪; 按固定频率更新 target network

10. episode 在 terminated 或 truncated 时停止采样

5.3 最低限度日志

维度	日志项
交互	environment steps、episodes、episode length、截断率
性能	game score、max tile、是否达到 2048、达到目标所需步数
探索	epsilon、随机动作比例、合法动作数量分布
优化	loss、gradient norm、learning rate、UTD ratio
价值	mean/max Q、TD error、target value、普通 DQN 与 Double DQN 的估计差
回放	buffer size、样本年龄分布、reward 分布、terminal/truncated 比例

6. 评估协议 (P0)

6.1 指标层级

层级	指标	解释
唯一主要指标	P(一局中达到 2048 或更大方块)	模型选择首先只看该指标
预设决胜规则	主指标统计上无法区分时, 看 P(达到 1024)	强调失败对局的最低质量; 也可事先改为 P(4096), 但不可事后选择
辅助曲线	P(max tile $\geq 2^k$), k 覆盖 8-13 等	展示稳定性与上限, 曲线交叉时不强行宣称全面占优
分数分布	均值、中位数、IQR、P90/P95、ECDF	避免只看长尾均值和单次最高分
训练稳定性	不同训练种子的主指标均值与置信区间	区别于同一个模型的对局波动

层级	指标	解释
成本	environment steps、optimizer updates、wall-clock time	区分样本效率与计算效率

6.2 种子安排

- **训练种子**：每个实验条件至少 5 个独立训练种子；算力允许时用 8–10 个。
- **快速开发评估集**：固定约 200 局，用于检查代码与明显退化，不用于最终结论。
- **验证种子集合**：固定约 1000–2000 局，所有候选 checkpoint 和超参数共享。
- **最终测试集合**：另一组从未参与调参的 4000–10000 局种子；只在方案冻结后运行。
- **统计报告**：伯努利成功率给出 Wilson 置信区间；模型间可利用共享种子做配对 bootstrap。

重要：“共享一组评估种子”指共享一个包含大量种子的固定集合，不是只用一个 seed。大量样本降低方差，共享集合提高模型间比较的可复现性。

7. 阶段化实验矩阵

实验必须按依赖关系推进。不要同时打开所有改进，否则无法判断性能变化来自哪里。

阶段	优先级	实验问题	固定项	改变项	晋级条件
E0 环境与基线	P0	规则、评估与种子是否可信	标准 2048 规则	仅策略类型	启发式 > 随机，结果可复现
E1 最小 DQN	P0	价值学习能否显著超过随机	指数+MLP、raw/linear reward、mask	训练预算	主指标稳定上升
E2 普通 vs Double	P0	选择-评价分离是否减少高估	其余完全相同	TD target	多种子统计比较
E3 γ 实验	P1	短视与稳定性的平衡	Double DQN、1-step	$\gamma \in \{0.99, 0.995, 1.0\}$	比较长长期诊断与最终指标
E4 n-step	P1	奖励传播是否更快	最佳 γ 、其余相同	$n \in \{1, 3, 5\}$	固定交互预算下曲线
E5 表示×网络	P1	输入编码和归纳偏置各自作用	训练协议	2×2 设计	避免混杂解释
E6 对称增强	P1	D4 增强能否提高样本效率	最佳基础架构	augmentation on/off	动作和 next_state 同步变换
E7 奖励变换	P1	数值稳定与任务偏好	算法/输入固定	raw、linear、log	分别解释尺度与目标变化
E8 高级结构	P2	Dueling/PER/VAE 的增量价值	强基线	一次只加一项	成本与收益均报告
E9 PPO 对照	P2	直接策略优化的稳定	环境/指标/表示尽量一	算法	environment steps

阶段	优先级	实验问题	固定项	改变项	晋级条件
		性与样本代价	致		与 wall time 双重公平

8. 关键受控实验的实施细节

8.1 表示与网络：采用 2×2 因子设计

实验	输入表示	网络	能回答的问题
A	16 维指数标量	MLP	最小基线
B	C×4×4 one-hot 展平	MLP	one-hot 本身是否有益
C	1×4×4 指数矩阵	无池化 CNN	CNN 归纳偏置本身是否有益
D	C×4×4 one-hot	无池化 CNN	组合是否产生交互效应

CNN 使用 stride=1，不做池化，避免在 4×4 棋盘上过早下采样。CNN 可能利用邻接关系，也可能因权重共享的平移假设与角落/绝对位置策略不完全匹配而失败。

8.2 长期回报与短视诊断

- **折扣因子实验：**先比较 $\gamma=0.99$ 、0.995、1.0；其余保持完全相同。
- **n-step 实验：**在选定 γ 后比较 1、3、5 步回报，避免与 γ 同时变化。
- **即时贪心率：**统计智能体动作是否等于当前一步合并分最高动作。
- **分支 rollout：**在固定诊断状态集上，为每个合法动作进行多次后续 rollout，估计长期回报并与智能体选择比较。
- **结构破坏案例：**记录导致最大块离开角落、空格骤减、单调性崩溃的动作；这些只作为诊断，不一定加入奖励。

8.3 奖励实验

方案	形式	是否改变偏好	主要风险
R0 原始	每步 merge score	作为原任务基准	大合并造成价值尺度很大
R1 线性缩放	merge score / K	理想情况下不改变动作排序	K 不合理会影响数值稳定和学习率有效尺度
R2 对数压缩	$\log(1+\text{merge score})$	会改变不同合并大小的相对价值	可能更稳定，但偏离原始分数目标
R3 结构 shaping	分数 + 空格/单调性等	明确加入先验偏好	先验可能限制后期策略发现

实验纪律：不要用最终测试集挑奖励。结构奖励必须单独标注为“改变任务目标的 shaping 实验”，不

能与纯分数奖励混在同一排行榜中而不说明。

8.4 对称性数据增强

D4 对称群包含 8 个不同变换，可由四种旋转与一种基础反射的组合生成。训练时不必把 replay 永久扩充八倍；采样 batch 后随机选一个变换 T 。

原转移：

(s, a, r, s_{next})

增强转移：

$(T(s), T(a), r, T(s_{next}))$

同时变换：

current valid mask

next valid mask

例：棋盘顺时针旋转 90°

up $\rightarrow$ right

right $\rightarrow$ down

down $\rightarrow$ left

left $\rightarrow$ up

标准化到最小字典序只需枚举 8 个候选，复杂度 $O(8 \times 16)$ ，并不存在计算困难；但当前基础路线优先使用随机数据增强，减少推理阶段变换与反射复杂度。

9. VAE 研究分支（P2，不进入首个基线）

VAE 不是因为“状态组合很多”就必需。它应当验证可被否证的具体假设。

假设	主要指标	成立证据	不成立证据
H1 提高样本效率	固定环境步数下 P(2048) 学习曲线/AUC	更少交互达到同一水平	曲线无提升或更慢
H2 提高最终性能	固定交互预算后的测试 P(2048)	多种子显著更高	相同或更低
H3 提高训练稳定性	训练种子间主指标方差/CI	方差明显更小	方差不变或更大
H4 提高计算速度	wall-clock 与吞吐量	每步训练更快	编码/重构使总时间更长

建议输入为 $C \times 4 \times 4$ one-hot（若 $C=16$ ，则展平为 256 维），候选 latent 32/64。回放池保存原始棋盘，每次采样用当前编码器重新编码。

- **公平比较：**固定环境交互次数、训练种子、调参预算，并分别报告参数量和 wall-clock。
- **联合训练风险：**同一棋盘的 latent 随编码器更新而漂移，Q 网络面对非平稳输入；重构目标也不保证保留决策相关信息。
- **预训练数据：**随机、启发式和 RL 状态可混合，但必须记录比例，并防止验证/测试轨迹泄漏。
- **必要对照：**相同参数规模的普通 encoder、冻结 VAE、联合 VAE，至少三者之一对照，否则无法归因。

10. PPO / Actor-Critic 对照 (P2)

PPO 的研究目的不是预设其一定更稳定或更好，而是比较“直接优化动作概率”与“学习 Q 值”的行为差异。

公平维度	DQN	PPO	报告方式
状态与环境	相同	相同	固定规则、奖励和动作 mask
数据预算	replay 可长期复用	rollout 批次复用若干 epoch	同时给 environment steps 与 updates
评估策略	masked argmax Q	masked argmax probability	验证测试均确定性
训练稳定性	多训练种子	多训练种子	主指标的均值/CI
计算成本	可能较多小 batch 更新	适合并行 rollout	wall-clock、吞吐量、显存

11. 实验执行顺序与停止规则

- 完成环境单元测试和种子复现。
- 运行随机、固定规则、启发式基线，并校准步数上限。
- 实现最小 Masked DQN，在一个训练种子上确认能够学习。
- 加入 target network 和 Double DQN；完成普通 DQN 对照。
- 冻结基础训练协议，使用至少 5 个训练种子形成可信基线。
- 依次做 γ 、n-step、表示 $\times$ 网络、D4 增强、奖励变换实验。
- 只有核心实验完成后，再做 VAE、Dueling/PER 或 PPO。
- 最终一次性在未使用的测试种子集合上评估，不再根据测试结果调参。

停止规则：任何新模块若连续多个训练种子都不能超过强基线，且增加明显复杂度，应先停止扩展，转向失败分析，而不是继续叠加更多组件。

12. 最终交付物清单

类别	交付物
代码	环境、策略基线、DQN/PPO、replay、mask、训练与评估

类别	交付物
	脚本、配置文件
测试	滑动/合并/生成/终止/种子/对称性单元测试
配置	每个实验的独立 YAML/JSON；可从 commit + config 重现实验
结果	学习曲线、成功率曲线、分布图、置信区间、训练种子汇总
诊断	Q 值/TD error、截断率、即时贪心率、失败棋盘案例
报告	假设、方法、控制变量、结果、局限性、负结果与下一步

13. 开始实验前的一页检查表

- ☐ 环境标准规则已通过单元测试。
- ☐ 同一 seed + 同一动作序列可复现。
- ☐ 无效动作不生成方块，基础方案在所有选择与 target 中使用 mask。
- ☐ 达到 2048 不终止；无合法动作才 terminated。
- ☐ 截断为 truncated=True，且 TD target 对截断状态 bootstrap。
- ☐ 步数上限由 episode length 与截断率校准，而非拍脑袋。
- ☐ 主要指标固定为 P(达到 2048)，测试集未参与调参。
- ☐ 普通 DQN 与 Double DQN 的差异只有 target 计算。
- ☐ 每个核心结论至少基于 5 个训练种子。
- ☐ 一次实验尽量只改变一个因素；表示 $\times$ 网络使用 2×2 因子设计。
- ☐ 所有曲线同时标注 environment steps；计算效率另报 wall-clock。
- ☐ VAE 和 PPO 不阻塞首个可靠 DQN 基线。

结论：现在应开始实现 E0（环境与基线），而不是继续停留在抽象算法选择。