

强化学习认知误区与 知识缺口复盘

基于 2048 DRL 项目设计过程的系统总结

学习复盘版 v1.0

目的不是记录“答错”，而是把曾经混淆的概念转化为可反复检查的知识框架。

依据前期多轮方案推演整理

目录与使用方式

这是一份执行型文档。建议先阅读“总体结论”，随后按阶段推进；每完成一个阶段，只允许进入下一阶段中标记为 P0 的项目。

1. 如何使用本复盘
2. 环境、MDP 与终止定义
3. 奖励、回报与价值函数
4. 评估统计与随机种子
5. 状态表示、CNN 与 VAE
6. 动作掩码与对称性
7. DQN、Double DQN、PPO 与策略概念
8. 实验设计和科研方法
9. 后续学习清单与自测题

1. 如何使用本复盘

下面的条目按“曾出现的认识 → 问题所在 → 更准确的理解 → 在项目中的检查方法”组织。它们并不代表能力不足；相反，这些是从课本概念进入真实 RL 工程时最常见、也最有价值的转折点。

整体评价：你的优势是能主动质疑指标、对称性、表示学习和长期回报；主要缺口不是公式记忆，而是把环境定义、学习目标、统计评价和算法实现严格区分。

2. 环境、MDP 与终止定义

2.1 无效动作后是否生成新方块

曾出现的认识	更准确的理解
曾认为即使动作不能移动或合并，原版游戏仍会生成新方块，因此“现在无效”的动作未来可能变有效。	在标准 2048 中，只有棋盘发生变化后才生成新方块。无效动作满足 $s' = s$ ，且不会因外部随机事件自己变成有效。让无效动作生成方块会构成自定义变体，并改变 MDP。

项目检查：写单元测试：对明显无效动作执行多次，棋盘、分数和随机数流都不得被消耗。

2.2 棋盘塞满是否等于终止

曾出现的认识	更准确的理解
曾把“棋盘塞满”直接作为结束条件。	满盘仍可能存在水平或垂直相等的相邻方块并继续合并。真正终止是四个动作都不能改变棋盘。

项目检查：分别测试“满盘但有两个相邻 64”和“满盘且所有相邻不同”的棋盘。

2.3 达到 2048：成功事件不等于终止事件

曾出现的认识	更准确的理解
最初把达到 2048 和无法移动都列为 episode 终止。	任务若定义为持续获得更高分和更大方块，达到 2048 应只是成功指标或奖励事件，游戏继续；是否终止必须服务于任务目标。

项目检查：环境 info 中记录 reached_2048，但 terminated 仅由无合法动作决定。

2.4 terminated 与 truncated 的类型和含义

曾出现的认识	更准确的理解
曾把 terminated、truncated 写成 reward 或 TD target 公式。	它们是布尔标记。terminated 表示 MDP 自然结束；truncated 表示外部时间/步数预算停止。reward 是单独的数值。

项目检查：达到步数上限输出 terminated=False、truncated=True，并保留最后 next_state。

2.5 截断时的 bootstrap

曾出现的认识	更准确的理解
对“步数结束后怎样继续计算 reward”感到困惑。	截断后并不继续真实模拟未来；价值方法用 Q/V 网络估计剩余价值。只有真正终止才令未来价值为 0。

项目检查：TD target 使用 (1-terminated)，而不是 (1-done)；若 done=terminated or truncated，不能直接拿 done 截断价值。

2.6 环境随机与策略确定性

曾出现的认识	更准确的理解
曾说 2048 转移是确定的，所以测试时无需随机决策。	标准 2048 的新方块位置和数值使转移随机。但在随机 MDP 中，最优策略仍可能是确定性的：给定同一棋盘选择期望回报最大的动作。

项目检查：验证/测试关闭探索并固定 tie-break；环境仍使用固定评估种子集合产生随机转移。

3. 奖励、回报与价值函数

3.1 零奖励不必然是惩罚

曾出现的认识	更准确的理解
曾认为无效动作 reward=0 就等于对它进行了惩罚。	奖励的好坏是相对未来回报而言。0 可能比正回报差，也可能与另一个有效但无合并动作相同。若 $\gamma=1$ 且是 0 奖励自循环，它甚至可能与立即行动价值相同。

项目检查：区分 r_t 、 G_t 、 $V(s)$ 、 $Q(s,a)$ ；检查无效自循环在不同 γ 下的 Bellman 方程。

3.2 即时奖励与动作长期价值

曾出现的认识	更准确的理解
曾把“有效但局面变差的动作”直接称作 negative reward。	该动作即时 reward 可以是 0，但因未来局面更差，其 Q 值为负面或较低。RL 的核心正是从后续结果学习这种延迟影响。

项目检查：日志中同时记录 merge reward、episode return 和估计 Q，不用即时 reward 替代长期判断。

3.3 γ 不是只影响收敛速度

曾出现的认识	更准确的理解
曾把 $\gamma < 1$ 与 $\gamma = 1$ 当作单纯技术参数比较。	γ 改变远期奖励权重，也使浪费一步的 0 奖励自循环在 $\gamma < 1$ 时产生时间成本； $\gamma = 1$ 更接近不折扣整局分数，但价值尺度和自循环问题更突出。

项目检查：独立比较 γ ，保持 reward、n-step 和网络完全一致。

3.4 线性缩放与非线性压缩不同

曾出现的认识	更准确的理解
曾把奖励缩放都视为训练优化，不会改变任务。	r/K 在理想情况下只是改变数值尺度； $\log(1+r)$ 改变大合并与小合并的相对比重，因而改变策略偏好和实际优化目标。

项目检查：报告 raw、linear、log 三种设置时，明确区分“稳定性处理”和“目标重定义”。

3.5 终局大 bonus 的尺度问题

曾出现的认识	更准确的理解
曾提出分数奖励加一个“很大的最终结果 reward”，但未定义相对尺度。	奖励项是否大取决于整局累计奖励尺度。过小不起作用，过大又成为稀疏、主导性信号；需要规范化、敏感性分析和独立消融。

项目检查：先统计整局 merge score 分布，再设候选 bonus，并报告它占 return 的比例。

3.6 奖励 shaping 与评价指标不是一回事

曾出现的认识	更准确的理解
担心只用分数奖励 “没有对结果 evaluate”。	评价指标用于实验结束后比较模型，不必全部放入训练奖励。把 P(2048) 作为评价不等于必须为达到 2048 加奖励。

项目检查：训练 reward 与 evaluation metrics 分开配置；避免为提高指标而无意改变任务。

4. 评估统计与随机种子

4.1 平均分 + 最高分的加权并不等于 80%/20% 重要性

曾出现的认识	更准确的理解
最初提出 $0.8 \times \text{平均分} + 0.2 \times \text{最高分}$ 。	权重只有在指标尺度相近时才可解释。最高分尺度大、随评估局数增长且极端依赖运气，0.2 的数值贡献可能反而超过平均分。

项目检查：最高分只作为展示；主要指标预先固定，多个指标不强行压成单一分数。

4.2 归一化的真正意义

曾出现的认识	更准确的理解
对为什么要归一化后再加权感到不理解。	归一化不是为了给智能体 “模糊状态”，而是在组合不同统计指标时把它们放到可比尺度；对状态输入的归一化则是另一件事。

项目检查：将 “指标归一化” “输入预处理” “奖励缩放” 分为三个独立概念。

4.3 相同子不是不公平

曾出现的认识	更准确的理解
曾认为模型应使用完全独立的随机局面才有意义。	不同种子会把策略差异与随机难度差异混在一起。所有模型共享一个大型固定种子集合可以减少比较噪声；不同策略仍会因动作不同而进入不同轨迹。

项目检查：训练种子独立；验证/测试种子集合对所有模型固定共享。

4.4 “一组种子”不是“一个 seed”

曾出现的认识	更准确的理解
担心验证只用一组会随机性很大。	一组指 $\{v_1, \dots, v_N\}$ 的大集合。扩大 N 降低单模型估计误差，共享集合支持配对比较。

项目检查：快速开发、验证、最终测试使用三个互斥集合，并给成功率置信区间。

4.5 两种方差不能混淆

曾出现的认识	更准确的理解
把分数方差统一称为模型稳定性。	单个模型跨对局的分数方差描述环境结果波动；同一算法跨训练种子的性能方差才描述训练稳定性。

项目检查：分别报告 within-run episode distribution 与 across-seed performance distribution。

4.6 概率曲线交叉时不存在无偏好的唯一优胜者

曾出现的认识	更准确的理解
希望多条达到方块概率线能自动给出统一比较。	一个模型可能更稳定达到 1024，另一个更容易偶尔达到 4096。曲线交叉意味着需要预先声明价值偏好，而不是用统计技巧消除偏好。

项目检查：主指标固定为 $P(2048)$ ；相同或无法区分时使用预设决胜规则，而非事后挑有利阈值。

4.7 最高值随样本量自然增长

曾出现的认识	更准确的理解
开始时把最高分当成较强能力指标。	评估局数越多，观察到极端好运的机会越大，因此不同 N 下最高值不可直接比较。

项目检查：所有模型评估局数一致；尾部用 P95、top 5% mean 或 ECDF，而非单次 max。

5. 状态表示、CNN 与 VAE

5.1 4×4 矩阵与 16 维向量的信息量相同

曾出现的认识	更准确的理解
曾认为棋盘“不能是向量”，至少必须是矩阵。	展平只是改变张量形状，不会丢失 16 个格子的数值。真正不同的是网络是否拥有空间邻接、权重共享等归纳偏置。

项目检查：用指数+MLP 与指数矩阵+CNN 分开比较，不以“矩阵更真实”作为结论。

5.2 输入归一化不必损失精确状态

曾出现的认识	更准确的理解
认为智能体必须得到准确指数，因此不应归一化。	可逆线性变换如 x/K 保留全部信息。归一化既属于状态预处理，也会影响网络优化；它与环境真实状态定义可以分开。

项目检查：环境内部保存整数棋盘；模型入口可单独转换，并在配置中记录。

5.3 One-hot 是“每个等级一张指示棋盘”

曾出现的认识	更准确的理解
一开始不确定 one-hot channel 的含义。	若有 C 个等级，则输入是 $C \times 4 \times 4$ ；每个格子只在对应等级通道为 1。它把等级当类别，而指数标量显式保留相邻等级关系。

项目检查：不要把 one-hot 和 CNN 同时更换后只归因于 one-hot；使用 2×2 实验。

5.4 CNN 不会因为“卷积”自动丢失所有特征

曾出现的认识	更准确的理解
担心卷积过程必然损失棋盘信息。	真正造成明显空间下采样的是 pooling、stride>1、过早压缩通道或全局平均。stride=1、无池化并保持 4×4 ，可避免直接丢格子。

项目检查：同时认识到 CNN 的平移权重共享不完全符合 2048 的绝对位置/角落策略。

5.5 巨大状态空间不等于高维单次输入

曾出现的认识	更准确的理解
因 2048 状态组合很多而自然想到用 VAE 压缩。	组合状态空间巨大，但单次指数输入只有 16 个数。VAE 的必要性取决于表示学习假设，不是由状态数量自动推出。

项目检查：先让简单 MLP/CNN 学到可靠基线，再问 VAE 是否提高样本效率或稳定性。

5.6 高重构准确率不保证决策信息保留

曾出现的认识	更准确的理解
最初把 VAE 压缩与“更好表现”直接联系。	重构目标偏向常见、像素/格子层面的信息；稀有但关键残局可能被忽略。对 RL 有用的信息未必是最有利于复原输入的信息。

项目检查：除 reconstruction loss 外，还要通过下游 P(2048)、诊断状态动作一致性验证。

5.7 联合编码器产生表示漂移

曾出现的认识	更准确的理解
后来意识到编码器变化可能让旧数据不可用，但概念尚不明确。	若 replay 保存旧 latent，会直接过时；保存原始棋盘并重新编码可避免旧 latent，但同一状态的表示仍随时间变化，使 Q 网络输入非平稳。

项目检查：回放保存原始棋盘；比较冻结、联合训练和普通 encoder。

5.8 “同样训练强度”不足以保证 VAE 消融公平

曾出现的认识	更准确的理解
曾用“同样训练强度”概括公平对照。	还需控制环境交互数、训练种子、参数量、预训练数据、调参预算；并分别报告样本效率和 wall-clock，因为 VAE 增加计算。

项目检查：预注册 H1/H2/H3 假设，不把学习快、最终好、稳定和运行快混为一个结论。

6. 动作掩码与对称性

6.1 动作掩码不是 Actor-Critic 专属

曾出现的认识	更准确的理解
曾觉得“网络输出四个动作但排除无效动作”听起来像 Actor-Critic。	动作掩码是状态相关动作空间处理，可用于 DQN、PPO、A2C 等算法；它不决定算法类别。

项目检查：mask 由环境规则产生，与 Q/logit 网络解耦。

6.2 掩码时不能宣称模型学会避免无效动作

曾出现的认识	更准确的理解
曾回答使用掩码既是“学习避免”也是“直接排除”。	若训练和测试始终掩码，模型根本没有选择无效动作的机会；它学习的是合法集合内的策略。只有允许无效经验时才能说它从后果中学习。

项目检查：报告中准确写“外部排除无效动作”，不夸大为学习能力。

6.3 TD target 也必须掩码

曾出现的认识	更准确的理解
曾认为只在动作执行时 mask，不影响 TD target。	下一状态无效动作若有错误高 Q，未掩码 max 会把它写入目标并污染所有前序价值。因此探索、贪心选择和 target 取值都需 mask。

项目检查：Double DQN 中 online 在合法动作中 argmax，target 只评价选出的 a^* 。

6.4 无掩码自循环与 γ 的关系

曾出现的认识	更准确的理解
对无法排除无效动作时怎样处理自循环不清楚。	无效转移 (s,a,0,s) 在 $\gamma < 1$ 时因时间折扣通常较差； $\gamma = 1$ 时可能与立即行动同值，导致空转。可用小负时间成本、有效性模型、样

曾出现的认识	更准确的理解
	本重加权或循环限制。

项目检查：2048 中合法性易模拟，因此基础方案优先精确 mask；无 mask 仅作独立变体。

6.5 合法对称不是平移

曾出现的认识	更准确的理解
最初把平移、旋转等本质相同状态一起考虑。	固定边界和角落使平移不保持游戏结构。正方形棋盘合法几何对称称为 D4 的 8 个旋转/反射。

项目检查：只使用 4 旋转 + 4 反射的变换集合。

6.6 生成操作少不等于最终变换少

曾出现的认识	更准确的理解
认为主/副对角线反射没意义，因为可由其他变化组合。	确实只需“旋转 + 一种反射”作为生成操作，但组合后仍得到 8 个不同群元素；可组合不代表可忽略。

项目检查：程序以 transform_id=0...7 枚举并测试 8 个不同结果。

6.7 标准形存在并列变换歧义

曾出现的认识	更准确的理解
曾认为不同变换得到同一标准态时，动作映射应自然一致。	对称棋盘可能被多个 T 映射成同一棋盘，但 T^{-1} 会把同一标准动作还原成不同原动作。必须使用确定的 transform_id 并列规则。

项目检查：候选键使用 (flattened_board, transform_id)，取最小元组。

6.8 数据增强仍需要动作映射

曾出现的认识	更准确的理解
后来倾向直接对全部状态做数据增强，以避开标准化反映射。	增强虽然无需选择唯一标准形，但转移中的 s、a、s'、两侧

曾出现的认识	更准确的理解
	mask 都必须用同一 T；只变棋盘不变动作会生成错误标签。

项目检查：写等变单元测试： $T(\text{step}(s,a)) == \text{step}(T(s),T(a))$ ，并控制随机生成位置。

7. DQN、Double DQN、PPO 与策略概念

7.1 DQN 不输出动作概率

曾出现的认识	更准确的理解
曾认为 DQN 中“输出四个价值”与“输出四个概率”两种都存在。	标准 DQN 输出四个 Q 值。动作概率由 ϵ -greedy 等行为策略额外构造。Distributional DQN 输出的是每个动作的回报分布，不是动作选择概率。

项目检查：查看网络最后一层和 loss：DQN 拟合 TD target；PPO Actor 优化概率比与 advantage。

7.2 策略不等于随机策略

曾出现的认识	更准确的理解
曾把“自然表示随机策略”理解为“是否学习策略”。	确定性映射 $\pi(s)=\text{argmax } Q$ 同样是策略。随机策略只是 $\pi(a s)$ 为概率分布的一种策略形式。

项目检查：2048 测试阶段可以采用确定性策略，训练探索另行添加。

7.3 目标网络与 Double DQN 解决不同问题

曾出现的认识	更准确的理解
曾把目标网络与 Double DQN 的作用写成同一件事。	目标网络缓解 bootstrap 靶值每步变化的移动目标问题；Double DQN 分离选择与评价，减轻 max 对正估计噪声的系统性偏好。

项目检查：普通 DQN 与 Double DQN 只切换 target 公式，target network 两者都保留。

7.4 过高估计会形成具体策略错误

曾出现的认识	更准确的理解
理解了正噪声会被 max 放大，但未能落到 2048 行为。	可能反复选择罕见但偶然高估的移动、错误破坏角落大块、把有利新方块的运气归因于动作、让错误 Q 向更早状态传播并提前停止探索。

项目检查：保存高 Q 但 rollout 长期回报差的状态动作，作为失败案例。

7.5 Replay buffer 不只是“把同一数据多训几次”

曾出现的认识	更准确的理解
主要把 buffer 理解为提升数据利用率。	它还打破相邻样本相关性、混合不同策略阶段数据并支持 off-policy 学习。但过高 UTD 会过拟合旧数据，分布陈旧也会造成误差。

项目检查：记录 UTD ratio、样本年龄和新旧数据比例。

7.6 PPO 不是完全不能复用数据

曾出现的认识	更准确的理解
曾概括 PPO 无法数据复用。	PPO 通常对同一批当前 rollout 做多个 epoch，但策略变化后旧数据很快不再匹配，不能像 DQN replay 一样长期反复使用。

项目检查：比较时同时记录 environment steps、每批 epoch 数和 gradient updates。

7.7 “PPO 稳定、DQN 不稳定”不是定律

曾出现的认识	更准确的理解
把两者优劣简化为 PPO 稳定、DQN 难训。	DQN 的函数逼近+bootstrap+off-policy 组合确实容易不稳；PPO 的 clipped update 经常较平滑。但 PPO 也会受 advantage 方差、critic、熵坍塌、奖励尺度影响。

项目检查：结论必须基于相同环境、表示、奖励和多训练种子，不可把常见经验当项目结果。

7.8 测试确定性不依赖环境确定性

曾出现的认识	更准确的理解
曾用“转移确定”解释为什么测试选最大动作。	选择确定性策略是为了评估已学策略并移除探索噪声，而不是因为环境转移确定。随机环境也可使用确定性最优策略。

项目检查：验证和测试 $\epsilon=0$ ；随机性仅来自环境评估 seed。

8. 实验设计和科研方法

8.1 同时改输入和网络会产生混杂

曾出现的认识	更准确的理解
最初计划直接比较“指数+MLP”与“one-hot+CNN”。	结果变化无法区分是表示方式还是网络归纳偏置造成。应采用 2×2 因子设计或分阶段单变量比较。

项目检查：至少包含指数/one-hot $\times$ MLP/CNN 四组，参数量差异也要记录。

8.2 “其他所有保持不变”需要可操作化

曾出现的认识	更准确的理解
能意识到要单变量实验，但未明确哪些量必须锁定。	固定训练种子集合、环境步数、网络、optimizer、reward、replay、评估 seed、checkpoint 选择规则；只改一个预注册参数。

项目检查：每个实验从配置 diff 自动生成差异清单。

8.3 步上限是定的一部分

曾出现的认识	更准确的理解
曾随意提出 1000 步作为方便采样的上限。	上限会把任务变为“在有限步内成功”，并可能截断优秀轨迹。应由自然长度分布和目标截断率决定。

项目检查：报告每个模型 truncated rate；若强模型经常截断，增大 horizon。

8.4 样本效率、收敛速度和 wall-clock 不同

曾出现的认识	更准确的理解
在 VAE 假设中把“高速学习”和“更好表现”合在一起。	样本效率看 environment steps；优化速度看 updates；运行速度看 wall-clock；最终性能看冻结预算后的测试指标。

项目检查：所有学习曲线至少以 environment steps 为横轴，并附 wall-clock 表。

8.5 训练一次得到高分不等于算法有效

曾出现的认识	更准确的理解
早期目标倾向“尽可能优秀”，但训练种子和不确定性未具体化。	神经 RL 方差高，必须跨训练种子报告均值、置信区间和失败运行；单次最好 run 只能展示。

项目检查：核心实验至少 5 seeds；不要只选择最成功 checkpoint 作为算法结论。

8.6 观察到相关性不等于机制成立

曾出现的认识	更准确的理解
例如模型常选即时高分动作，就直接认为短视。	需要长期动作价值的独立估计或 rollout 对照。即时贪心率只是线索，不能单独证明因果。

项目检查：构造固定诊断状态集，对每个动作做多次分支 rollout。

8.7 测试集不可参与方案选择

曾出现的认识	更准确的理解
对大量随机评价有正确直觉，但尚未完全区分验证与最终测试。	验证集用于调参和 checkpoint；最终测试集只在方案冻结后使用。反复看测试结果会形成隐性过拟合。

项目检查：测试结果出来后如需改模型，建立新一代测试集或明确该结果不再是无偏最终结果。

8.8 复杂模块应回答明确假设

曾出现的认识	更准确的理解
VAE 最初以“状态空间大”为引入理由。	每个模块应有可证伪假设、主要指标、失败条件和额外成本。否则复杂度本身会掩盖负结果。

项目检查：为 VAE、对称增强、n-step、PPO 分别写一页实验卡。

9. 当前仍需补强的知识模块

模块	需要掌握到的程度	在 2048 项目中的实践
Bellman 方程与 bootstrap	能从 terminated/truncated 推导 target	手算普通 DQN 与 Double DQN batch target
Off-policy 与 replay	理解行为策略、目标策略、数据陈旧与 UTD	记录 replay 年龄和更新比
统计推断	比例 CI、bootstrap、训练种子 vs 对局种子	对 P(2048) 给 Wilson CI 和多 seed 汇总
奖励设计	区分 scale、transform、shaping 与 evaluation	raw/linear/log/structure 分离实验
函数逼近归纳偏置	理解 MLP/CNN/one-hot 的信息与结构差异	2×2 表示网络实验
PPO/Actor-Critic	理解 policy loss、critic、advantage、on-policy 近似	作为后续算法对照
表示学习	理解重构目标、latent drift、预训练与联合训练	VAE 仅在强基线后实验
实验方法	预注册假设、控制变量、负结果和复现	配置驱动、固定种子和最终测试

10. 高频概念对照表

容易混淆的概念	区别
state vs representation	state 是环境信息；representation 是交给模型的编码/预处理。
reward vs return	reward 是一步信号；return 是未来奖励的折扣和。
return vs Q value	return 是一次轨迹样本；Q 是给定状态动作后的期望 return。
terminal vs success	terminal 表示 MDP 不再继续；success 是人为关注的事件或指

容易混淆的概念	区别
	标。
terminated vs truncated	自然结束 vs 外部预算停止；后者通常继续 bootstrap。
policy vs stochastic policy	动作规则 vs 输出概率分布的一类策略。
target network vs Double DQN	稳定移动目标 vs 减轻 max 高估。
masking vs learning invalidity	外部排除动作 vs 从无效经验中学习。
linear scaling vs log transform	主要改尺度 vs 改变奖励相对偏好。
episode variance vs training variance	同一模型对局随机性 vs 多次训练的不稳定。
sample efficiency vs wall-clock	所需环境交互数 vs 实际耗时。
large state space vs high-dimensional observation	可能状态数量多 vs 单次输入元素多。

11. 后续自测题

10. 为什么一个 truncated 状态的 TD target 通常仍包含 $Q(s',a')$ ，而 terminated 状态不包含？
11. 当 $\gamma=1$ 、无效动作产生 $(s,a,0,s)$ 时，为什么它可能不比有效动作差？
12. 在 Double DQN 中，online 网络和 target 网络分别做哪一步？两者都需要 mask 吗？
13. 为什么把 one-hot+CNN 与指数+MLP 直接比较无法判断 one-hot 是否有益？
14. 为什么共享 5000 个测试种子通常比每个模型独立抽 5000 个种子更适合比较？
15. 为什么 $\log(1+r)$ 不只是“让训练更稳定”，而是改变了任务偏好？
16. VAE 重构准确率很高，为什么仍可能让策略变差？
17. 正方形只有一个基础反射操作即可生成全部对称，为什么最终仍有 8 个不同变换？
18. 测试策略为什么可以是确定性的，即使环境随机？
19. 一次训练达到很高分，为什么不能证明算法优于基线？

12. 一页式复习清单

- ☐ 先定义 MDP，再定义训练 reward，最后独立定义 evaluation metrics。
- ☐ 成功、终止、截断是三个不同概念。
- ☐ 0 reward 不是自动惩罚；看的是预期 return。
- ☐ DQN 学 Q ；PPO Actor 学动作概率；二者都在学习策略。
- ☐ 动作 mask 必须用于探索、贪心和 next-state target。
- ☐ Target network 稳定靶值；Double DQN 分离选择与评价。
- ☐ 相同大型评估种子集合提高公平性和复现性。
- ☐ 不同训练种子衡量算法训练稳定性。
- ☐ 矩阵与向量可含相同信息；网络结构决定归纳偏置。
- ☐ One-hot 和 CNN 是两个变量，不能一次混在一起归因。

- ☐ CNN 无池化不等于信息必丢，但平移归纳偏置可能不匹配。
- ☐ VAE 必须服务于可证伪假设，不是“大状态空间”的默认答案。
- ☐ 数据增强仍要同步变换动作、next_state 与 masks。
- ☐ 线性奖励缩放和非线性压缩含义不同。
- ☐ 所有核心结论必须基于多个训练种子、未参与调参的测试集合和置信区间。

这些误区已经被识别出来，本身就是项目最有价值的学习成果之一。